

Rapport d'evaluation - SocialMetrics AI

Analyse de sentiments de tweets - TF-IDF + Regression logistique

1. Jeu de donnees

Source des donnees : Fichier database/seed.sql

Nombre total de tweets annotes : 139

Annotation : positive=1 si positif, negative=1 si negatif.

Categories : positifs (1,0), negatifs (0,1), neutres (0,0), mixtes (1,1). Le jeu melange des tweets en anglais et francais.

2. Modele

Deux modeles independants de regression logistique sont

entraînés : l'un prédit le label 'positive', l'autre 'negative'.

Chaque texte est vectorisé avec TfidfVectorizer (unigrammes et bigrammes). La regression logistique utilise class_weight='balanced' pour compenser le desequilibre des classes.


Le score final renvoyé par l'API vaut $P(\text{positif}) - P(\text{negatif})$, borné entre -1 (très negatif) et +1 (très positif).

3. Protocole d'evaluation

Validation croisée stratifiée à 5 plis

(cross_val_predict) : chaque tweet est prédit lorsqu'il appartient au pli de test. La matrice de confusion est donc agréger sur les 139 tweets, ce qui réduit la variance liée à la petite taille du jeu de données.

Matrice de confusion - Sentiment positif



Matrice de confusion - Sentiment negatif

verite terrain

Non Negatif

57

15

Negatif

21

46

Non Negatif

Negatif

Prediction

55

50

45

40

35

30

25

20

15

4. Mesures detaillees (precision, rappel, F1-score)

Modele positif

Exactitude (accuracy) : 0.719

Matrice de confusion : VN=52 FP=20 FN=19 VP=48

Mesures par classe :

Classe 0 (absence) -> precision 0.732 | rappel 0.722 | F1 0.727

Classe 1 (presence) -> precision 0.706 | rappel 0.716 | F1 0.711

Moyenne ponderee -> precision 0.720 | rappel 0.719 | F1 0.719

Modele negatif

Exactitude (accuracy) : 0.741

Matrice de confusion : VN=57 FP=15 FN=21 VP=46

Mesures par classe :

Classe 0 (absence) -> precision 0.731 | rappel 0.792 | F1 0.760

Classe 1 (presence) -> precision 0.754 | rappel 0.687 | F1 0.719

Moyenne ponderee -> precision 0.742 | rappel 0.741 | F1 0.740

Lecture des matrices

VN = vrais negatifs, FP = faux positifs,

FN = faux negatifs, VP = vrais positifs.

precision = $VP / (VP + FP)$: fiabilite des predictions positives.

rappel = $VP / (VP + FN)$: capacite a retrouver les cas positifs.

F1 = moyenne harmonique de la precision et du rappel.

5. Analyse, biais et recommandations

Forces

- Les tweets clairement positifs ou negatifs sont bien separees grace a un vocabulaire polarise (love, excellent / hate, awful).
- L'usage de bigrammes capture des expressions comme 'not work'.
- `class_weight='balanced'` limite le biais vers la classe majoritaire.

Faiblesses et erreurs frequentes

- Les tweets MIXTES (1,1) sont les plus difficiles : un meme texte contient des indices positifs et negatifs (ex. 'great design but poor performance'), ce qui provoque des faux positifs/negatifs.
- Les tweets NEUTRES (0,0) factuels peuvent etre mal classes si un mot ambigu apparait.
- La negation et l'ironie ne sont que partiellement captees par TF-IDF.

Biais possibles

- Biais de vocabulaire : le modele s'appuie sur des mots-cles ; un tweet positif sans terme fortement polarise peut etre manque.
- Biais linguistique : melange anglais/francais avec un corpus reduit, les mots rares d'une langue sont sous-representes.
- Biais de taille : jeu de donnees encore reduit, les mesures conservent une variance non negligeable malgre la validation croisee ; il faut confirmer les resultats sur un corpus plus grand.

Recommandations

- Augmenter fortement le volume de tweets annotes (plusieurs milliers) et equilibrer les quatre categories.
- Ajouter un pretraitement : normalisation, gestion des emojis, des hashtags, des mentions et de la negation.
- Tester des n-grammes plus larges, un lemmatiseur et un reglage d'hyperparametres (`C`, `min_df`) par validation croisee.
- Envisager un modele unique multi-label ou un classifieur a 3 classes (negatif / neutre / positif) pour mieux gerer les cas ambigus.
- Mettre en place un suivi des mesures a chaque reentrainement hebdomadaire pour detecter toute derive du modele.